

Predicción de recompra de clientes

Online Retail II — Modelo de probabilidad de recompra a 6 meses

Daniel Ribes · Máster en Machine Learning — Trabajo final

31 de mayo de 2026 · github.com/danribes/ml-trabajo-final-online-retail

1 · Contexto de negocio y objetivo

El encargo. Como data scientist de un retailer online (UK, artículos de regalo, muchos clientes mayoristas), identificar entre la base de clientes a quienes tienen **alta probabilidad de volver a comprar**, para accionar campañas diferenciadas.

Objetivo del modelo

Estimar, para cada cliente, **P(recompra en los próximos 6 meses)** a partir de su historial transaccional.

Por qué importa

- **Fidelización** → clientes con alta probabilidad.
- **Retención / win-back** → clientes con baja probabilidad.

Hipótesis de partida

- El comportamiento **RFM** (recencia, frecuencia, gasto) discrimina la recompra.
- La **intensidad de compra** (ritmo, dispersión del gasto) añade señal sobre el RFM clásico.

2 · El dataset

Online Retail II (UCI ML Repository) — todas las transacciones de un retailer online UK sin tienda física, **01-12-2009 → 09-12-2011** (24 meses, 2 hojas Excel).

1.07 M

líneas de transacción

8

columnas

24

meses de histórico

~5.8 K

clientes con ID

Columna	Tipo	Descripción
Invoice	Nominal	Nº factura (6 díg.). Prefijo c = cancelación
StockCode	Nominal	Código de producto
Description	Nominal	Nombre del producto
Quantity	Numérico	Unidades por línea
InvoiceDate	Fecha	Fecha y hora de la factura
Price	Numérico	Precio unitario (£)
CustomerID	Nominal	Identificador de cliente
Country	Nominal	País de residencia

3 · Vista previa de los datos

Carga de las 2 hojas concatenadas → 1.067.371 filas × 8 columnas. `df.head()` :

Invoice	StockCode	Description	Quantity	InvoiceDate	Price	CustomerID	Country
489434	85048	15CM CHRISTMAS GLASS BALL 20 LIGHTS	12	2009-12-01 07:45	6.95	13085	United Kingdom
489434	79323P	PINK CHERRY LIGHTS	12	2009-12-01 07:45	6.75	13085	United Kingdom
489434	79323W	WHITE CHERRY LIGHTS	12	2009-12-01 07:45	6.75	13085	United Kingdom
489434	22041	RECORD FRAME 7" SINGLE SIZE	48	2009-12-01 07:45	2.10	13085	United Kingdom
489434	21232	STRAWBERRY CERAMIC TRINKET BOX	24	2009-12-01 07:45	1.25	13085	United Kingdom

Grano = **línea de factura** (un producto). El modelo trabaja a nivel **cliente**, así que habrá que agregar por `CustomerID` .

4 · Calidad de los datos

Diagnóstico (df.info + nulos)

- CustomerID nulo: 22,8 % → no etiquetables.
- Description nulo: 0,4 % → impacto mínimo.
- 34.335 duplicados exactos.
- Rango fechas confirmado: 2009-12 → 2011-12.

→ Estas observaciones definen las reglas de limpieza de la slide 7.

Anomalías detectadas

- Cancelaciones (Invoice empieza por c).
- Códigos de servicio: POST , DOT , M , AMAZONFEE ... (no son producto).
- Quantity ≤ 0 y Price ≤ 0 (devoluciones / errores de captura).
- Outliers de revenue por línea (cola larga).

Metodología

Cómo se traduce el problema de negocio en un problema de ML

5 · Enfoque metodológico y justificación

Decisión	Elección	Por qué
Tipo de problema	Clasificación binaria supervisada (recompra sí/no)	Negocio quiere rankear clientes por probabilidad, no predecir un importe
Unidad de análisis	El cliente (no la transacción)	La acción comercial se dirige a personas → agregamos por <code>CustomerID</code>
Diseño temporal	Fecha de corte + ventana de label de 180 días	Evita <i>data leakage</i> ; simula la predicción real: "hoy predigo los próximos 6 meses"
Features	RFM clásico + intensidad de compra	Estándar en CRM/retail, interpretable para negocio y con buena señal
Algoritmos	Baseline lineal + 3 modelos de árbol	Relaciones no lineales y colas largas → árboles; sin "volvemos locos" (brief)
Métrica primaria	AUC (+ AP y Brier)	Target balanceado (~52 %) y problema de <i>ranking</i> ; Brier controla la calibración
Validación	Holdout 75/25 estratificado + CV en el tuning	Estimación honesta del rendimiento fuera de muestra

6 · Pipeline de extremo a extremo

1. **Carga** + control de calidad de datos
2. **Limpieza** y filtrado defendible
3. **Fecha de corte** + variable objetivo
4. **Feature engineering** (RFM + extras)
5. **Análisis exploratorio** (EDA)
6. **Modelado** — LogReg, RF, XGBoost, LightGBM
7. **Optimización** — RandomizedSearchCV
8. **Diagnóstico** — ROC, calibración, lift
9. **Importancia** de variables
10. **Uso de negocio** — segmentación por decil

Todo el pipeline es **reproducible**: `build_pipeline.py` regenera artefactos, métricas y figuras; el notebook se ejecuta de principio a fin sin intervención manual.

7 · Limpieza y exclusiones

Criterio: cada exclusión debe ser defendible ante negocio. De 1,07 M de líneas → 798.641 líneas limpias / 5.823 clientes.

Filtro	Filas eliminadas	Justificación
CustomerID nulo	~243 K	Sin ID no se puede modelar la recompra del cliente
Cancelaciones (c*)	~20 K	Eventos negativos, no compras
Códigos de servicio	~2 K	POST , DOT , AMAZONFEE ... no son producto
Quantity ≤ 0 ó Price ≤ 0	varios	Devoluciones / errores de captura
Outliers top 0,5 % revenue/línea	~5 K	Estabilidad de los modelos lineales (cap £305)

8 · Definición de la variable objetivo

Esquema temporal

- **Entreno** con transacciones `< 2011-06-09`.
- **Etiqueto** con compras en `[2011-06-09, 2011-12-06]` (180 días).
- `Repurchase = 1` si el cliente vuelve a comprar **al menos una vez** en esa ventana.

El corte cae **6 meses antes** del final del dataset → deja una ventana completa para observar la recompra.

4.914

clientes en
periodo pre-
corte
(modelables)

51,6 %

tasa de recompra
(positivos)

Target prácticamente balanceado → **sin necesidad de re-muestreo**; AUC es métrica primaria válida.

9 · Feature engineering — RFM + intensidad

Agregación por cliente sobre el periodo pre-corte. 12 variables en 3 familias:

RFM clásico

- Recency — días desde la última compra
- Frequency — nº de facturas
- Monetary — gasto total

Volumen

- NLines , NProducts , Tenure

Intensidad / patrón


- BuysPerMonth — ritmo de compra
- AvgTicket , AvgLine , AvgQty
- StdRevenue — dispersión del gasto
- IsUK — mercado doméstico

CustomerID	Recency	Frequency	Monetary	AvgTicket	AvgQty	StdRevenue	IsUK
12347	62	4	3.146,75	786,69	12,5	21,15	0
12348	64	4	1.388,40	347,10	56,5	28,35	0
12349	223	2	2.221,14	1.110,57	9,9	17,34	0

Análisis exploratorio


Las gráficas que orientaron el modelado

10 · EDA — Ingresos mensuales y fecha de corte




Lectura. Tendencia creciente con pico estacional en **Q4** (campaña navideña). La línea de corte (2011-06-09) cae **a mitad de la curva** → la ventana de label captura comportamiento representativo, no solo el pico.

11 · EDA — Balance del target y concentración geográfica




~52 % recompran → clases equilibradas.



~85 % del revenue es UK.

Implicaciones. (1) Sin desbalance fuerte → AUC fiable y sin re-muestreo. (2) **IsUK** aporta poca señal discriminante (casi todo es UK) — se confirma luego en la importancia de variables.

12 · EDA — Distribución de las variables RFM



Lectura. `Recency`, `Frequency` y `Monetary` presentan **colas largas / asimetría** marcada → los modelos **basados en árboles** (insensibles a la escala y capaces de captar no linealidades) deberían rendir mejor que un lineal puro.

Modelado y resultados

13 · Comparación de algoritmos (Línea Base)

Estrategia: un *baseline* lineal interpretable + tres modelos de árbol sobre las **12 variables RFM clásicas**. Split holdout **75/25 estratificado** (3.685 train / 1.229 test). Métricas en test:

Modelo	AUC	AP	Brier
Logistic Regression (<i>baseline</i>)	0,7955	0,8201	0,1845
Random Forest (best baseline)	0,8030	0,8329	0,1800
XGBoost	0,7887	0,8227	0,1941
LightGBM	0,7782	0,8125	0,2286

- Los árboles baseline apenas superan al lineal, sugiriendo que con 12 variables RFM clásicas el techo de performance ronda **AUC ≈ 0.80**.

14 · Enriquecimiento + Optimización (Optuna)

Para superar el límite del RFM clásico, enriquecimos el dataset a **30 variables** y optimizamos los modelos con **Optuna** (TPE bayesiano en LGBM/XGB/RF con CV de 5 folds).

1. Variables Enriquecidas

- **Intervalos de compra (IPI):** Media, std, y CV de días entre compras (`IPI_mean` , `IPI_std` , `IPI_cv`).
- **Tendencias:** Ratio de gasto en 1ª mitad vs 2ª mitad de la tenure (`RevenueTrend`).
- **Recencia:** Compras en últimos 30/60/90 días.
- **Ratios:** Diversidad de productos (`ProductDiversity`) e interacción Recencia x Frecuencia.

2. Tuning con Optuna

- **Espacio:** 100 trials con TPE sampler y MedianPruner.
- **Ganador:** XGBoost (CV AUC: **0,8107**).
- **Parámetros:** `depth=3` , `n_est=607` , `lr=0.009` , `subsample=0.97` , `colsample=0.49` , `spw=1.22` .

15 · Elección del modelo final: Baseline vs Optuna



El enriquecimiento comportamental y la optimización sistemática con Optuna permitieron romper el techo del 0.80 de AUC en test.

Modelo	Features	Tuning	AUC Test	AP Test	Brier
Random Forest (<i>baseline</i>)	12 (RFM)	Ninguno	0,8030	0,8329	0,1800
XGBoost (<i>Optuna final</i>)	30 (Enriquecido)	Optuna	0,8141	0,8389	0,1791

Por qué destaca el modelo final:


- **Mayor discriminación** → +1.11 pp de AUC y +0.60 pp de Average Precision (AP).
- **Mejor calibración** → Brier Score baja a **0,1791**, lo que asegura que el score refleja probabilidades reales.
- **Robustez** → Al usar profundidad baja (`max_depth=3`) y regularización (`alpha=0.77`), evitamos el sobreajuste.

16 · Diagnóstico — ROC y calibración



Lectura. Curva ROC con el modelo final XGBoost liderando (AUC 0,814). La curva de calibración sigue la diagonal ideal → las **probabilidades son muy fiables** y usables directamente para segmentar, sin recalibración obligatoria.

17 · Importancia de variables




Top drivers

1. **Recency** — cuánto hace de la última compra
2. **BuysPerMonth** — ritmo de compra mensual
3. **IPI_mean** — media de días entre compras
4. **Monetary** — gasto acumulado

IsUK ≈ 0 → confirma lo visto en EDA.

Las nuevas variables comportamentales (como los intervalos entre compras y recencia reciente) han aportado la señal clave para superar al baseline.

18 · Vista de negocio — lift por decil de score



96,7 %

recompra en el decil TOP (vs 51,6 % base)

12,2 %

recompra en el decil más bajo

El score ordena la base de forma **monótona y accionable**: un gradiente claro de probabilidad por decil.

19 · Conclusiones y propuesta de uso

El modelo final (XGBoost, AUC 0,814) separa con fiabilidad a quién retener de a quién fidelizar. Plan accionable por decil de score:

Segmento (decil)	Probabilidad	Acción comercial
9–10	Alta	Fidelización: programa VIP, acceso prioritario a colecciones, NPS
5–8	Media	Cross-sell: cupones personalizados, recomendación por afinidad
0–4	Baja	Retención / win-back: descuento agresivo + encuesta de churn

Drivers de la decisión: **Recency**, **ritmo de compra**, **días promedio entre compras (IPI)** y **gasto** — altamente interpretables.

20 · Próximos pasos

1. **Validación temporal *rolling*** — repetir con cortes alternativos para medir robustez.
2. **Nuevas features** — categoría de producto, estacionalidad (pico Q4), recurrencia por SKU.
3. **Optimizar el umbral** con curva coste/beneficio (coste de campaña vs CLV recuperado).
4. **Re-entreno trimestral** + monitorización de *drift* en las variables RFM.
5. **Restricciones monótonas** sobre Recency/Frequency en un gradient boosting.
6. **Calibración fina** (Platt / isotónica) si se pasa a una segmentación binaria dura.

Gracias

¿Preguntas?

github.com/danribes/ml-trabajo-final-online-retail